

Fenntarthatóság Plusz pontos feladat beszámoló

A projekt célja a különböző nagy nyelvi modellek (LLM) ökológiai lábnyomának és energiahatékonyságának összehasonlító elemzése volt. A mérésekhez a kiadott munkafüzet alapján az Ollama futtatókörnyezet volt, amelyet Python `subprocess` lett alkalmazva, a környezeti hatások becsléséhez pedig a CodeCarbon könyvtár volt integrálva. A vizsgálat során a kapott négy modellt (qwen3.5, qwen3.5:0.8b, llama2:7b és tiny-llama:1.1b) teszteltem három különböző területen: kódolás, logika és kreatív szövegírás.

A megvalósítás lépései

A fejlesztés első fázisában kialakítottam egy automatizált mérési csővezetékét. Minden modellhívást egy-egy dedikált `EmissionsTracker` kontextusba zártam, amely rögzítette a CPU, GPU és RAM energiafelhasználását. A benchmark feladatokat úgy állítottam össze, hogy reprezentálják a tipikus felhasználási módokat: egy rekurzív algoritmus megírását, egy matematikai fejtörőt és egy absztrakt vers generálását. Az összegyűjtött nyers adatokat Pandas keretrendszerben tisztítottam és rendszereztem, majd vizualizációs könyvtárak (Seaborn, Matplotlib) segítségével több dimenzióban is elemeztem.

Az eredmények elemzése és értékelése

A mérési adatok összefüggést mutattak a modellméret és a kibocsátás között. A legnagyobb, qwen3.5 (9.6B) modell produkálta a legmagasabb abszolút CO₂-kibocsátást, különösen a kreatív írás során, ahol a komplexebb generálás miatt jelentősen megnőtt a következtetési idő. Ezzel szemben a tinyllama:1.1b és a llama2:7b modellek rendkívül alacsony fogyasztás mellett teljesítették a feladatokat.

A fajlagos hatékonyságot vizsgálva (g CO₂ / 100 karakter) érdekes megfigyelés, hogy a kisebb modellek nem minden esetben hatékonyabbak: a qwen3.5:0.8b például viszonylag sok energiát igényelt az előállított szövegmennyiséghez képest a TinyLlama-hoz viszonyítva. A generálási sebesség és a fenntarthatóság összevetésekor beigazolódott a fordított arányosság: a kisebb, optimalizált modellek nagyságrendekkel több karaktert állítottak elő másodpercenként, miközben átlagos kibocsátásuk a minimumon maradt.

Következtetés

A projekt rávilágított arra, hogy az AI rendszerek tervezésekor a pontosság mellett a környezeti hatást is kritikus tényezőként kell kezelni. A választott módszertan alkalmas arra, hogy objektív képet adjon a modellek futtatási költségeiről, segítve a fenntarthatóbb technológiai döntések meghozatalát.

Az eredmények elemzése

A mérési adatok és az ábrák alapján az alábbi következtetéseket vonhatóak le:

1. Modellméret és kibocsátás kapcsolata:

- A qwen3.5 (9.6B) modell rendelkezik a legmagasabb abszolút CO₂-kibocsátással, különösen a kreatív feladatoknál. Ez várható volt, hiszen a több paraméter nagyobb számítási kapacitást és hosszabb következtési időt igényel.
- A tinyllama:1.1b és llama2:7b meglepően alacsony fogyasztást mutattak a specifikus benchmarkunk során.

2. Feladatspecifikus variancia (Hő térkép):

- A kreatív írás generálta a legtöbb kibocsátást a Qwen modelleknél, ami a hosszabb és komplexebb válaszgenerálásnak köszönhető.
- A logikai feladatok (rövid válaszok) minden modellenél a legkisebb ökológiai lábnyommal jártak.

3. Energiahatékonyság (g CO₂ / 100 karakter):

- Bár a nagyobb modellek abszolút értékben többet fogyasztanak, a hatékonysági mutató felfedi, hogy a qwen3.5:0.8b fajlagosan nagyon drágán (sok energiával) állít elő egységnyi szöveget a TinyLlama-hoz képest.

4. Sebesség vs. Fenntarthatóság (Kettős tengelyű ábra):

- Megfigyelhető egy fordított arányosság: a kisebb, optimalizáltabb modellek (pl. TinyLlama) sokkal több karaktert képesek generálni másodpercenként, miközben az átlagos CO₂-kibocsátásuk (piros vonal) a minimumon marad.
- A qwen3.5 esetében a lassabb generálási sebesség és a magasabb fogyasztás együtt jelenik meg, ami a modell komplexitását tükrözi.